Jurnal Informatika Teknologi dan Sains (JINTEKS)
E-ISSN : 2686-3359
Submit Agustus 02, 2024 | Revised Agustus 19, 2024 | Accepted Agustus 30, 2024

Hal. 728-736
Vol. 6; No. 3
Agustus 2024

ANALISIS SENTIMEN TERKAIT PERSEPSI KEAMANAN DATA INFORMASI DAN PRIVASI DI INDONESIA MENGGUNAKAN PENDEKATAN *MACHINE LEARNING*

Alvali Zaqi Taufan[1*], Wahyu Wibowo[2]
[1,2]Magister Manajemen Teknologi, Institut Teknologi Sepuluh Nopember Surabaya
email: alvalizaqi@gmail.com[1*]

Abstrak: Peningkatan penetrasi pengguna internet di Indonesia, dengan data pengguna internet 2023 Indonesia yang telah mencapai 213 juta, menimbulkan masalah baru bagi keamanan data, informasi dan privasi di dalamnya. sementara disisi lain pengesahan UU PDP pada September 2022 belum menunjukkan dampak signifikan bagi penanganan kasus kebocoran data maupun solusi bagi masyarakat yang sudah dirugikan. Tujuan dari penelitian ini adalah mengetahui sentimen masyarakat terkait keamanan data, informasi dan privasi di Indonesia, sehingga dapat memberikan rekomendasi kepada organisasi terkait penyusunan aturan turunan UU PDP melalui hasil sentimen masyarakat. Penelitian ini menggunakan pendekatan *Machine Learning* dengan metode klasifikasi menggunakan perbandingan 2 metode yakni: *Random Forest, Support Vector Machine*, untuk memperoleh tingkat keakuratan yang paling baik berdasarkan hasil prediksi sentimen yang muncul. Ruang lingkup penelitian yang diambil merupakan cuitan yang dibuat oleh masyarakat Indonesia di *twitter* (x.com). Hasil yang diperoleh adalah *Linear Support Vector Machine* menjadi model klasifikasi *machine learning* terbaik dengan tingkat akurasi mencapai 92.6% dan AUC 97%. Selain itu, dihasilkan juga beberapa rekomendasi dalam hal penyusunan aturan turunan berupa penguatan sumber daya manusia untuk pelindungan data, serta penyusunan konten strategis untuk meningkatkan edukasi dan kepedulian keamanan siber di Indonesia.

Kata Kunci: Data, Informasi, *Machine Learning*, UU PDP, *Random Forest, Support Vector Machine*

Abstract: *The increasing penetration of internet users in Indonesia, with data on Indonesia's 2023 internet users reaching 213 million, raises new problems for data security, information and privacy in it. while on the other hand, the ratification of the PDP Law in September 2022 has not shown a significant impact on handling data leakage cases or solutions for people who have been harmed. The purpose of this study is to determine public sentiment related to data security, information and privacy in Indonesia so as to provide recommendations to organizations related to the preparation of derivative rules of the PDP Law through the results of public sentiment. This research uses machine learning approach with comparison of 2 methods: Random Forest and Support Vector Machine. The scope of research taken is tweets made by Indonesians on twitter (x.com). The results obtained are Linear Support Vector Machine being the best machine learning classification model with an accuracy rate of 92.6% and AUC 97%. In addition, several recommendations were also made in terms of drafting derivative regulations in the form of strengthening human resources for data protection, as well as drafting strategic content to increase cybersecurity education and awareness in Indonesia.*

Keywords*: Data, Information, Machine Learning, PDP Law, Random Forest, Support Vector Machine*

PENDAHULUAN

Seiring dengan perkembangan zaman, yang mana memasuki era modern dan digitalisasi seperti sekarang ini, teknologi informasi berkembang pesat dan menjadi kebutuhan sehari-hari yang penting bagi masyarakat, sehingga menunjang berbagai aktivitas yang dapat dilakukan dengan cepat, akurat dan tepat, serta berimbas pada peningkatan produktivitas [10]. Dilansir dari Survei Asosiasi Penyelenggara Jasa Internet Indonesia (APJII) yang mencatat penetrasi internet di Indonesia telah mencapai 78,19 persen pada 2023 atau menembus 215.626.156 jiwa dari total populasi Indonesia yakni sebesar 275.773.901 jiwa [5]. Hal ini sejalan juga dengan indikasi adanya peningkatan serangan maupun ancaman yang terjadi pada ruang siber. Data dari Badan Siber dan Sandi Negara menunjukkan bahwa data pada tahun 2022 mencapai 310 kasus dengan sektor pemerintahan mencapai 98 kasus (31%) dari total kasus keseluruhan yang ada, adapun jumlah kasus terbanyak berada pada bulan September tahun 2022 dengan 119 dugaan kasus kejadian [19]. Sejak UU No.27 Tahun 2022 terkait Pelindungan Data Pribadi tersebut disahkan, pada bulan September 2022, terdapat 35 kasus hingga 3 bulan setelahnya pada tahun 2022, tentu angka tersebut terus bertambah seiring *exposure* dan peningkatan penetrasi internet di Indonesia, terlebih saat ini Indonesia telah menerapkan Sistem Pemerintahan Berbasis Elektronik. Disisi lain, hingga saat ini pihak pemerintah yang bertanggung jawab dalam kepatuhan Penyelenggara Sistem Elektronik (PSE) yakni Kominfo dan keamanan sistem informasi yang berada di tangan Badan Siber dan Sandi Negara (BSSN) belum menyusun aturan turunan sebagai dukungan pelaksanaan teknis dari undang-undang tersebut. Berbagai tanggapan telah dikemukakan dan diulas oleh masyarakat melalui berbagai platform sosial media maupun media pemberitaan lainnya, tanggapan maupun reaksi negatif dan positif yang muncul pun beragam, namun hingga saat ini Badan Siber dan Sandi Negara sebagai organisasi yang memiliki tugas dan tanggung jawab terkait keamanan ruang siber di Indonesia belum pernah melakukan analisis terkait persepsi masyarakat mengenai keamanan data, privasi dan

Jurnal Informatika Teknologi dan Sains (JINTEKS)
E-ISSN : 2686-3359
Submit Agustus 02, 2024 | Revised Agustus 19, 2024 | Accepted Agustus 30, 2024
Hal. 728-736
Vol. 6; No. 3
Agustus 2024

informasi di Indonesia. Untuk itu, tujuan dari penelitian ini adalah untuk mengetahui sentimen masyarakat, baik sentimen positif maupun negatif, mengetahui perbandingan hasil tingkat akurasi ketepatan klasifikasi sentimen dari serangkaian algoritma prediktif yang digunakan yakni: Algoritma *Random Forest* dan *Support Vector Machine*, sehingga dapat memberikan rekomendasi terhadap organisasi dalam rangka menyusun upaya peningkatan program keamanan siber bagi masyarakat Indonesia, serta aspek apa saja yang harus dibahas lebih detail dalam aturan turunan Undang-Undang Pelindungan Data Pribadi (UU PDP).

TINJAUAN PUSTAKA

Analisis Sentimen

Analisis Sentimen menurut Chandani (2015) adalah proses yang bertujuan untuk menentukan isi dari dataset yang berbentuk teks bersifat positif, negatif atau netral. Dimana saat ini, pendapat khalayak umum menjadi sumber yang penting dalam pengambilan keputusan seseorang. Berdasarkan pengertian ahli di atas, maka dapat disimpulkan analisis sentimen adalah suatu proses komputasional dengan menggunakan algoritma tertentu yang digunakan untuk mengevaluasi perspektif dari seseorang yang dituangkan dalam bentuk, opini, gagasan, perasaan, serta emosional yang terkandung dalam teks, untuk memahami apakah suatu teks mengandung sentimen positif, negatif, atau netral. Analisis sentimen termasuk dalam ranah *text mining* yang mana saat ini sudah populer dengan menggunakan algoritma *machine learning*. Dalam penelitian ini sentimen yang dianalisis adalah sentimen positif, netral dan negatif [3].

Undang-Undang Pelindungan data Pribadi

Undang-Undang Pelindungan Data Pribadi merupakan Undang-Undang yang mengatur mengenai asas; jenis data pribadi; hak subjek data pribadi; pemrosesan data pribadi; kewajiban pengendali data pribadi dan prosesor data pribadi dalam pemrosesan data pribadi; transfer data pribadi; sanksi administratif; kelembagaan; kerja sama internasional; partisipasi masyarakat; penyelesaian sengketa dan hukum acara; larangan dalam penggunaan data pribadi; dan ketentuan pidana terkait pelindungan data pribadi. Pelindungan Data Pribadi adalah keseluruhan upaya untuk melindungi data pribadi dalam rangkaian pemrosesan data pribadi guna menjamin hak konstitusional subjek Data Pribadi [12].

Random Forest

Random Forest merupakan jenis algoritma *ensemble learning* yang menggunakan banyak pohon keputusan untuk meningkatkan akurasi prediksi. Algoritma tersebut menerapkan prinsip pemisahan biner secara rekursif, sehingga didapatkan node akhir dalam struktur pohon berdasarkan hasil dari klasifikasi maupun regresi. Metode ini dikembangkan oleh Leo Breiman dan Adele Cutler. Adapun prinsip kerja dari algoritma ini adalah sebagai berikut:

a. Bagging (*Bootstrap Aggregating*): Membuat sampel acak dari dataset asli dengan penggantian.
b. Pemilihan fitur acak: Setiap pohon dibangun menggunakan subset fitur yang dipilih secara acak.
c. Voting mayoritas: Untuk klasifikasi, kelas yang paling banyak diprediksi oleh pohon-pohon individual menjadi hasil akhir.
d. Rata-rata prediksi: Untuk regresi, hasil akhir adalah rata-rata dari prediksi semua pohon.

Penggunaan algoritma *Random Forest* untuk klasifikasi dapat diterapkan pada data *imbalance* dalam jumlah besar dengan memberikan hasil performa yang baik dan waktu eksekusi yang cepat [11].

Support Vector Machine

Menurut (Yin et al., 2011) *Support Vector Machine* (SVM) adalah suatu metode klasifikasi yang digunakan untuk menemukan nilai *hyperplane* dalam meningkatkan akurasi untuk menemukan solusi terkait suatu pola data.. *Support Vector Machine* (SVM) mampu meminimalisasi risiko prinsip secara terstruktur, dengan menghasilkan prediksi baru yang dapat menghindarkan kemungkinan masalah *overfitting* pada suatu data [14]. SVM dapat diuji dengan menggunakan model *linear* SVM dan RBF. *Linear* SVM berdasarkan garis lurus, sementara RBF berdasarkan *gaussian line* [8].

Berdasarkan pengertian tersebut, *support vector machine* pada prinsipnya bekerja atas prinsip *Structural Risk Minimization* (SRM) sehingga didapatkan *hyperplane* terbaik yang memisahkan dua buah *class* pada *input space*. *Hyperplane* pada prinsipnya akan membagi ruang berdimensi n menjadi dua bagian, tujuan SVM adalah menemukan titik terbaik dari dua set objek yang berasal pada dua class. Margin adalah jarak antara *hyperplane* tersebut dengan *pattern* terdekat dari masing-masing *class*. *Pattern* yang paling dekat ini disebut sebagai *support vector* [6] .

Pendekatan Penelitian

Jurnal Informatika Teknologi dan Sains (JINTEKS)
E-ISSN : 2686-3359
Submit Agustus 02, 2024 | Revised Agustus 19, 2024 | Accepted Agustus 30, 2024
Hal. 728-736
Vol. 6; No. 3
Agustus 2024

Penelitian ini menggunakan metode *hybrid* (*mixed method*) dengan menggabungkan pendekatan kuantitatif dan kualitatif. Pendekatan kuantitatif sendiri berbasis pada pengolahan statistik baik secara deskriptif maupun prediktif dengan menggunakan metodologi *machine learning* dan pengolahan data statistik. Sementara pendekatan kuantitatif berfokus pada pemahaman mendalam terkait objek teks yang dilakukan analisis. Pendekatan penelitian dengan menggunakan *mixed method* digunakan untuk mendapatkan pemahaman yang lebih komprehensif terhadap masalah penelitian [15].

Penelitian Terdahulu

Berbagai penelitian terkait analisis sentimen telah banyak dilakukan diantaranya oleh Leelawat et al (2022) mengenai analisis sentimen pariwisata di Thailand dengan menggunakan 3 metode algoritma *machine learning*: *Support Vector Machine* (SVM), CART, dan *random forest*, dimana hasilnya berdasarkan perbandingan 3 metode tersebut Algoritma *Support Vector Machine* (SVM) paling akurat dalam menganalisis sentimen dan *tweet* dalam Bahasa Inggris yang menyebutkan kata Bangkok, Phuket, dan Chiang-Mai [7]. Penelitian lain juga dilakukan oleh Hidayatullah *et al*. (2021), terkait performa aparat penegak hukum yakni Polisi dengan menggunakan metode *naïve bayes*, dimana hasilnya adalah Algoritma *Naive Bayes* sangat efektif dalam permasalahan klasifikasi atau penggolongan. Algoritma ini bekerja berdasarkan probabilitas yang sudah ada untuk menentukan probabilitas yang akan datang [4].

METODOLOGI PENELITIAN

Pengumpulan Data

Data yang diambil mengandung spesifik kata kunci tiga aspek tersebut (data, informasi, dan privasi), termasuk organisasi yang berkaitan di dalamnya yakni Kominfo dan BSSN. Melalui analisis sentimen tersebut, nantinya akan dilakukan klasifikasi terkait sentimen positif dan negatif menggunakan algoritma *machine learning* yakni*: support vector machine*, *naïve bayes*, serta *random forest*. Alasan peneliti menggunakan 3 algoritma tersebut adalah berkaitan dengan dataset yang dimiliki mencapai 10.151 cuitan. Selain itu secara keseluruhan, ketiga algoritma ini memiliki kekuatan unik yang membuat mereka sangat cocok untuk tugas-tugas klasifikasi *text mining*, mulai dari kesederhanaan dan efisiensi *Naïve Bayes* hingga kemampuan menangani data berdimensi tinggi dari SVM dan *robustness* dari *Random Forest* termasuk implementasi yang dilakukan pada kasus peneliti. Pengambilan data secara resmi akan dilakukan pada tanggal 01 Februari 2024 hingga 07 April 2024, dengan mempertimbangkan limitasi terkait *scraping web* dari pihak X (twitter). Data yang diobservasi akan dibagi menjadi 2 bagian, antara lain: data sebelum Undang-Undang Pelindungan Data Pribadi (UU PDP) disahkan yakni sebelum tanggal 20 September 2022 dan setelah tanggal tersebut. Hingga proses pengambilan data selesai dilakukan yakni 07 April 2024. Data yang diambil diperoleh dari API *platform twitter* yang dipanggil pada susunan program yang telah ditulis sebagai sebuah fungsi *web scraping* yang telah dilakukan. Hasil dari data tersebut berupa data berbentuk *javascript object notation* (JSON) yang telah dikonversi dalam bentuk .csv.

Tahapan Penelitian

Penelitian ini menggunakan analisis sentimen dan perbandingan hasil performa ketepatan dari algoritma klasifikasi yang ditetapkan yakni: *support vector machine*, *naïve bayes classifier*, dan *random forest* terkait persepsi keamanan data, privasi dan informasi di Indonesia. Analisis dilakukan dengan *tools python* sebagai bahasa pemrograman yang digunakan pada saat melakukan *scraping* data, dan untuk *built up script* algoritma yang digunakan. Adapun tahapan penelitian yang dilakukan antara lain:

1. Pengumpulan dataset dengan melakukan *scraping data*:

Web Scraping merupakan proses pengambilan data pada sebuah website. *Web Scraping* sendiri akan mengumpulkan serangkaian dataset yang berisi komentar, *tweet*, dan *retweet* pengguna terkait persepsi keamanan data, privasi dan informasi di Indonesia. Dimana didapatkan 10.151 cuitan (*tweets*), selama periode pengumpulan data yang dimulai dari 1 Februari 2024 – 7 April 2024

2. Melakukan *Preprocessing Text*

Preprocessing text merupakan tahapan yang dilakukan untuk menjamin data yang diproses sudah dalam keadaan bersih dan terhindar dari *noise*. Proses pembersihan data yang dilakukan antara lain, melakukan *removing* untuk data yang kosong, menghapus salah satu baris dari data yang duplikat, memeriksa inkonsistensi data dan memperbaiki kesalahan pada data. Biasanya data yang kosong disebabkan oleh adanya data baru yang belum ada informasinya [13]. Adapun langkah-langkah yang dilakukan pada tahapan ini adalah sebagai berikut.

a. *Data Cleansing*

Pada tahapan ini akan dilakukan terkait pembersihan data *missing value* atau tidak memiliki nilai sama sekali di dalamnya, namun tergenerate pada saat *web scraping*.

b. *Case Folding*

Jurnal Informatika Teknologi dan Sains (JINTEKS)
E-ISSN : 2686-3359
Submit Agustus 02, 2024 | Revised Agustus 19, 2024 | Accepted Agustus 30, 2024
Hal. 728-736
Vol. 6; No. 3
Agustus 2024

Tahapan ini bertujuan untuk mengeliminasi serangkaian dan sensitivitas huruf (besar atau kecil) yang ada pada dataset yang telah didapatkan, menjadi satu format yang sama, sehingga mendapatkan struktur kata maupun kalimat yang lebih konsisten contoh: "Data Bocor" menjadi "data bocor".

c. *Tokenizing*

Merupakan tahapan yang bertujuan untuk membedakan antara pembatas kata dan pembatas non-kata, tahapan ini dilakukan dengan melakukan penghapusan tanda baca seperti simbol dan tanda baca yang tidak penting, dan penghapusan spasi. Contoh: "data bocor,,,,,," menjadi "data" "bocor".

d. *Stemming*

Tahapan *stemming* merupakan fase yang diperlukan untuk mengurangi jumlah indeks nilai data yang berbeda sehingga kata-kata yang memiliki sufiks atau awalan kembali ke bentuk dasarnya.

e. *Filtering*

Merupakan tahapan terpenting dalam fase *preprocessing text*, dimana tahapan ini bertujuan untuk mengekstrak kata-kata penting dari dataset yang telah dikumpulkan, pada tahapan ini, kata-kata tidak memiliki arti spesifik dalam kalimat dapat dihilangkan.

3. *Feature Extraction*

Tahapan ini merupakan proses perhitungan frekuensi kemunculan kata menggunakan model vektor *Term Frequency - Inverse Document Frequency* (TF-IDF). Pada tahapan ini juga dilakukan penilaian cuitan dengan membandingkan kata yang muncul terhadap acuan *lexicon dictionary* yang digunakan, seperti penjelasan pada poin 1 sebelumnya. Hasilnya adalah bobot suatu kata berdasarkan mekanisme TF-IDF, dan hasil sentimen berdasarkan *lexicon based*. Adapun rumsu yang digunakan pada mekanisme ini adalah sebagai berikut [16].

$$TF\ (t,d) = \left(\frac{jumlah\ kemunculan\ t\ dalam\ d}{jumlah\ total\ kata\ dalam\ d}\right) \quad (1)$$

$$IDFj = \log\left(\frac{D}{dfj}\right) \quad (2)$$

4. Membuat analisis deskriptif dan diagnostik hasil *feature extraction*

Tahapan ini akan dilakukan analisis terkait kata apa saja yang sering muncul baik pada saat sebelum Undang-Undang Pelindungan Data Pribadi disahkan atau sebelum dan sesudahnya. Tahapan ini juga akan memvisualisasikan dan menjelaskan hasil perolehan data dalam bentuk grafik *word cloud*.

Tabel. 1 Aturan Sentimen

No.	Aturan	Kriteria
1.	Positif	>0
2.	Negatif	<0
3.	Netral	=0

5. Melakukan Klasifikasi

Pada tahapan klasifikasi ini akan dilakukan kategorisasi suatu kata yang telah dilakukan proses preprocessing hingga *feature extraction*, yang akan menghasilkan apakah suatu cuitan dikategorikan sebagai sentimen positif, netral atau sentimen negatif, melalui 2 algoritma yang digunakan dalam penelitian ini, yakni antara lain: *random forest* dan *support vector machine*.

6. Melakukan Evaluasi dan Interpretasi Hasil

Proses evaluasi dilakukan dengan cara membandingkan hasil dari model analisis sentimen menggunakan tabel *confusion matrix*. Tabel tersebut merupakan alat bantu untuk mengevaluasi model, apakah pada hasil klasifikasi yang dianalisis masih terdapat prediksi yang sifatnya *false positive*, *false negative*, *true positive*, dan *true negative*, termasuk akurasi, presisi, *recall* .

7. Diskusi dan Pembahasan

Dalam tahapan ini akan dilakukan rekomendasi strategik berdasarkan hasil interpretasi dari sentimen analisis maupun pemodelan topik, baik interpretasi yang diperoleh dari prediksi maupun klasifikasi langsung dari model yang digunakan. Dimana hasil dari perbandingan 2 algoritma yakni: *random forest*, dan *support vector machine*, akan menentukan model mana yang akan dipilih untuk memprediksi sentimen yang berkaitan dengan keamanan data, informasi dan privasi di Indonesia di masa yang akan datang, sehingga organisasi yang berkaitan dengan hal tersebut dapat meningkatkan kualitas layanan dalam rangka menyusun upaya peningkatan program keamanan siber dan awareness bagi masyarakat Indonesia berkaitan dengan keamanan data, privasi dan informasi.

Jurnal Informatika Teknologi dan Sains (JINTEKS)
E-ISSN : 2686-3359
Submit Agustus 02, 2024 | Revised Agustus 19, 2024 | Accepted Agustus 30, 2024
Hal. 728-736
Vol. 6; No. 3
Agustus 2024

Kerangka Penelitian

Berdasarkan tahapan penelitian yang telah diuraikan dan terdiri atas langkah-langkah analisis dalam pemenuhan tujuan, berikut adalah diagram alir sesuai dengan uraian-uraian tersebut yang ditunjukkan pada Gambar 1 berikut.

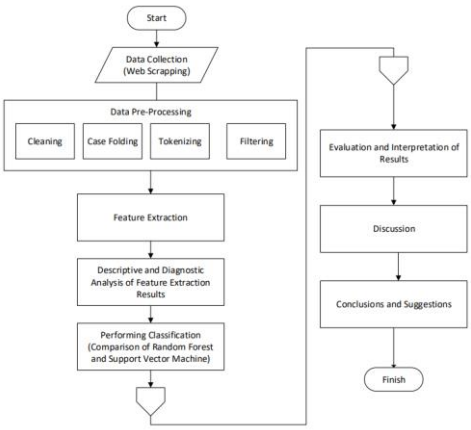

Gambar 1. Kerangka Penelitian

HASIL DAN PEMBAHASAN

Statistika Deskriptif Data Cuitan pada Twitter

Berdasarkan Gambar 2 diketahui bahwa masyarakat memiliki kecenderungan untuk membicarakan Kominfo sebagai pihak yang paling terkait dan terindikasi oleh masyarakat sebagai pihak yang seharusnya bertanggung jawab terkait dengan keamanan data, informasi, privasi di Indonesia. Hal ini cukup mendasar, mengingat secara infrastruktur tanggung jawab Pusat Data Nasional ada pada Kominfo, dan regulasi yang berkaitan dengan Penyelenggaraan Sistem Elektronik maupun Aplikasi Informatika secara nasional juga ada di Kominfo.

Berdasarkan Gambar 3 terdapat peningkatan tajam terkait cuitan pada bulan Maret, dengan total 2.846 *tweet* (cuitan), yang merupakan puncak tertinggi dalam periode dimana data diambil. Disusul oleh Bulan Februari dan April yang juga menampilkan sejumlah besar *tweet* (cuitan), dengan masing-masing 1202 dan 865 *tweet*. Bulan Juni memiliki jumlah *tweet* terendah pada 199. Peningkatan signifikan pada bulan Maret dapat dikaitkan dengan peristiwa atau insiden besar yang terkait dengan keamanan data yang telah menarik perhatian publik.

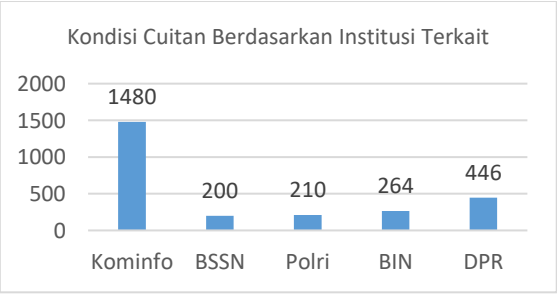

Gambar 2. Kondisi Cuitan Berdasarkan Institusi Terkait

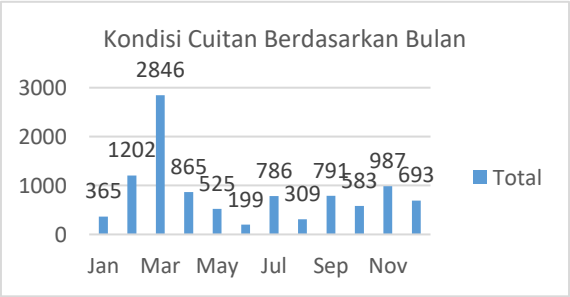

Gambar 3. Kondisi Cuitan Berdasarkan Institusi Terkait

Berdasarkan hasil proses *feature extraction* dan *labelling text*, dengan membandingkan hasil *preprocessing* pada tahapan akhir yakni *filtering* dengan berbagai kumpulan *terms* (kata) positif dan negatif dari *lexicon dictionary*, diperoleh hasil bahwa 59.9% sentimen masyarakat Indonesia keamanan data informasi dan privasi di Indonesia cenderung negatif dengan 6076 cuitan. Selanjutnya 989 cuitan terindikasi netral (9.7%), dan hanya 3086 cuitan yang memiliki sentimen positif (30.4%). Angka 59.9 % menunjukkan sentimen negatif yang tinggi berdasarkan penelitian Liu, B. (2012) [9].

Jurnal Informatika Teknologi dan Sains (JINTEKS)
E-ISSN : 2686-3359
Submit Agustus 02, 2024 | Revised Agustus 19, 2024 | Accepted Agustus 30, 2024
Hal. 728-736
Vol. 6; No. 3
Agustus 2024

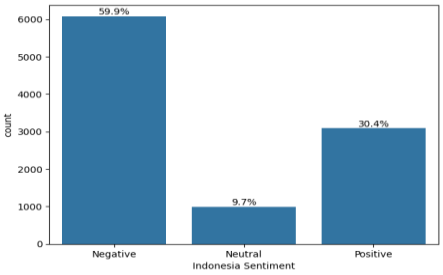

Gambar 4. Hasil Sentimen Berdasarkan Pelabelan Teks

Word Cloud Visualization

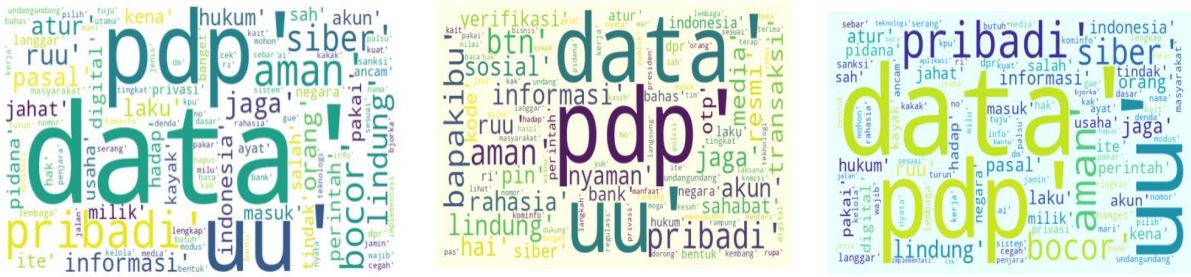

(a) *Wordcloud* Umum **(b) *Wordcloud* Positif** **(c) *Wordcloud* Negatif**

Gambar 5. Wordcloud Terkait Keamanan Data Informasi dan Privasi di Indonesia

Secara keseluruhan terlihat jelas bahwa kata ‘uu’, ‘data’ dan ‘pdp’, menjadi konteks yang paling sering dibicarakan, yang memiliki interpretasi bahwa masyarakat Indonesia pada umumnya cukup *concern* terhadap keamanan data, dan regulasi pelindungan data pribadi. Dalam *word cloud* positif masih terdapat beberapa sentimen positif yang menganggap uu pdp sebagai tonggak utama penerapan *data protection* di Indonesia, termasuk seruan untuk mengamankan data pribadi. Karena dalam UU PDP sendiri, terdapat 2 jenis data pribadi yang diatur dalam Pasal 4 UU PDP, hal ini dibuktikan dengan kata jaga dan lindung yang masuk dalam *word cloud* positif. Sementara *word cloud* pada sentimen negatif pada umumnya membahas hal yang berkaitan dengan manajemen tata kelola data dan informasi, keluhan terkait kebocoran data dan imbasnya terhadap kehidupan sehari-hari, persepsi masyarakat tentang buruknya *data protection* di Indonesia terutama yang berkaitan dengan sistem dan infrastruktur, serta regulator yang kurang aktif dalam memperbaiki layanan yang berkaitan dengan isu tersebut. Hal ini dibuktikan dengan munculnya kata bocor dan ‘pidana’ yang muncul pada *wordcloud* sentimen negatif.

Berdasarkan hasil analisis *word cloud* yang telah dilakukan, baik secara umum maupun sentimen positif dan negatif, peneliti mencoba menampilkan kata yang dapat dijadikan rujukan untuk menjadi perhatian bagi regulator dalam hal peningkatan upaya *awareness* maupun program keamanan siber, serta pembahasan yang perlu menjadi pertimbangan untuk dimasukkan dalam aturan turunan UU PDP. Adapun pembahasan yang perlu dipertimbangkan berdasarkan frekuensi kemunculan kata (*terms*) akan disajikan pada tabel 2 dan 3 sebagai berikut:

Tabel 2. Rekap *Terms Frequency* Sentimen Positif

No	Kata Positif	Frekuensi Kemunculan
1.	Nyaman	583
2.	Otp	542
3.	Rahasia	620
4.	transaksi	605
5.	Pin	638
6.	Jaga	706
7.	verifikasi	558

Tabel 3. Rekap Terms Frequency Sentimen Negatif

No	Kata Negatif	Frekuensi Kemunculan
1.	Bocor	1122
2.	Lindung	783
3.	Pidana	273
4.	Sanksi	185
5.	Langgar	232
6.	Sistem	187
7.	Cegah	134

Analisis Model Klasifikasi

Algoritma Random Forest

Berdasarkan perintah tersebut diketahui bahwa nilai (*n_estimator* = 200), hal ini menunjukkan bahwa trees yang digunakan adalah 200. Dasar pengambilan parameter ini ada pada penelitian "Implementasi *Random Forest* dan *Gradient Boosting* pada Klasifikasi Indeks Pembangunan Manusia (IPM)" [1], dan "*Analysis of Stroke Classification Using Random Forest Method*" oleh [2]. Dalam 2 penelitian tersebut, *Random Forest* digunakan dengan 100, 50, 200, dan 500 *trees* untuk memprediksi penyakit jantung dan mengklasifikasikan Indeks Pembangunan Manusia dalam bentuk *trees* = 200. Hasil menunjukkan bahwa performa *Random Forest* dengan

Jurnal Informatika Teknologi dan Sains (JINTEKS)
E-ISSN : 2686-3359
Submit Agustus 02, 2024 | Revised Agustus 19, 2024 | Accepted Agustus 30, 2024
Hal. 728-736
Vol. 6; No. 3
Agustus 2024

200 trees lebih baik daripada yang menggunakan 50, 200, dan 500 *trees*. Hasil dari 2 penelitian tersebut juga menunjukkan bahwa tingkat *accuracy* di atas 80%. Pada penelitian pertama yakni analisis klasifikasi stroke menggunakan *random forest* dengan *trees* = 200, tingkat *accuracy* 86.30%, *precision* 13.58%, *recall* 32.89 %, dan *f1 score* 19.23 %. Selanjutnya, pada penelitian kedua yakni berkaitan dengan klasifikasi Indeks Pembangunan Manusia dengan *trees* = 200, didapatkan hasil *accuracy* mencapai = 95%, *precision* = 97%, *sensitivity* = 91%, dan *specificity* = 98 %. Berdasarkan hasil dari 2 penelitian tersebut dan dengan mempertimbangkan dataset peneliti yang memiliki > 10.000 *instances*, peneliti mencoba untuk mengambil n_*estimators* = 200). Setelah melalui proses penetapan *trees*, langkah selanjutnya adalah melakukan evaluasi model *random forest*, untuk melihat seberapa jauh model *random forest* yang digunakan dapat memprediksi sentimen dari suatu cuitan yang berkaitan dengan keamanan data, privasi dan informasi di Indonesia. Tahapan selanjutnya adalah melakukan evaluasi model *random forest*, dimana pada tahapan ini terbagi menjadi 2 jenis metode yang digunakan pada model *random forest*, yakni model *random forest count vectorizer*, dimana model ini tidak terpengaruh pada TF-IDF *vectorizer*, dan model *random forest* TF-IDF *vectorizer* yang mempertimbangkan pembobotan kata dari data *training* dan data *testing* yang telah dilakukan *splitting*. Adapun hasil evaluasi *confusion matrix* masing-masing, ditampilkan pada tabel 4 dan 5 sebagai berikut.

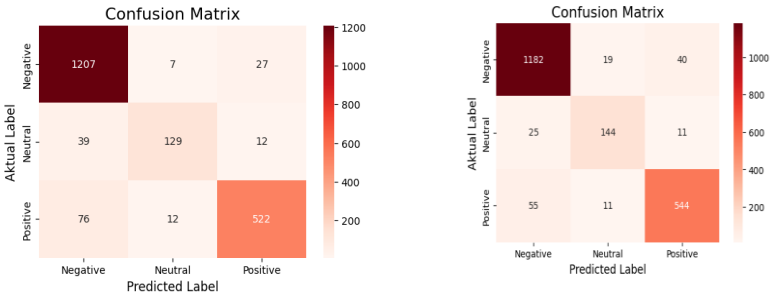

(a) *Random Forest Count Vectorizer* (b) *Random Forest TF-IDFVectorizer*

Gambar 5. *Wordcloud* Terkait Keamanan Data Informasi dan Privasi di Indonesia

Tabel 4. *Confusion Matrix Random Forest Count Vectorizer*

Label Kelas	TP (%)	TN (%)	FP (%)	FN (%)
Negatif	58.19	34.97	3.94	2.90
Netral	7.09	89.65	1.48	1.77
Positif	26.78	67.47	2.51	3.25

Tabel 5. *Confusion Matrix Random Forest Count TF IDF Vectorizer*

Label Kelas	TP (%)	TN (%)	FP (%)	FN (%)
Negatif	59.45	33.23	5.66	1.67
Netral	6.35	90.21	0.94	2.51
Positif	25.70	68.05	1.92	4.33

Algoritma *Support Vector Machine*

Selain algoritma *random forest*, peneliti juga membandingkan dengan algoritma klasifikasi lainnya yakni algoritma *Support Vector Machine* (SVM). Peneliti memilih SVM sebagai satu algoritma tambahan untuk dibandingkan dengan dua algoritma lainnya, dikarenakan SVM dapat bekerja dengan mencari *hyperplane* (garis pemisah) terbaik yang memisahkan kelas-kelas berbeda dalam ruang fitur multidimensi. Kelas yang digunakan dalam penelitian ini adalah kelas sentimen positif, negatif dan netral. Jenis SVM yang digunakan dalam penelitian ini adalah *Linear Support Vector Machine*. SVM dapat memaksimalkan margin antara *hyperplane* dan titik-titik data terdekat (disebut *support vectors*). Hal ini disebabkan data teks telah merepresentasikan ruang fitur yang berdimensi sangat tinggi. Terlebih dalam penelitian ini, peneliti menggunakan representasi seperti *bag-of-words*. Dalam ruang berdimensi tinggi pada kasus *text mining* yang dilakukan oleh peneliti data memiliki kecenderungan lebih tersebar, sehingga dalam penelitian ini *linear* SVM sudah dirasa cukup dari sisi performa dan akurasi. Adapun berikut merupakan hasil analisis *confusion matrix* dari *Linear Support Vector Machine* terdapat pada tabel 6 berikut.

Gambar 6. *Confusion Matrix Linear Support Vector Machine*

Jurnal Informatika Teknologi dan Sains (JINTEKS)
E-ISSN : 2686-3359
Submit Agustus 02, 2024 | Revised Agustus 19, 2024 | Accepted Agustus 30, 2024
Hal. 728-736
Vol. 6; No. 3
Agustus 2024

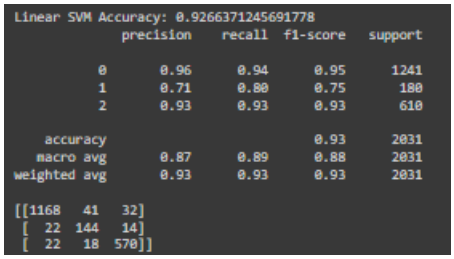

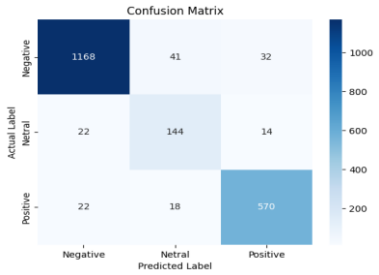

Tabel 6. ***Confusion Matrix Linear Support Vector Machine***

Label Kelas	TP (%)	TN (%)	FP (%)	FN (%)
Negatif	57.53	35.85	2.17	3.59
Netral	7.09	88.21	2.90	1.77
Positif	28.06	67.71	2.27	1.97

Evaluasi dan Interpretasi Model

Area Under Curve sendiri merupakan metriks yang menunjukkan kinerja model klasifikasi pada semua ambang batas (*thresholds*) klasifikasi. Berdasarkan hasil evaluasi model dengan mempertimbangkan 2 faktor utama yakni *accuracy* dan *area under curve*, dari 2 model yang diuji, secara keseluruhan kelima model dapat diterapkan pada analisis sentimen terkait keamanan data, privasi dan informasi di Indonesia, dengan posisi berada di atas 70 %, artinya apabila organisasi ingin menggunakan 2 model di atas untuk analisis sentimen, hasilnya dapat diterima dan dipertanggung jawabkan. Secara keseluruhan, AUC dan akurasi terbaik ada pada model *Linear Support Vector Machine*, yang masuk dalam kategori sangat baik untuk AUC maupun tingkat akurasinya, sehingga model tersebut dapat diterima dan diimplementasikan [17][18].

Tabel 7. Perbandingan AUC dan Accuracy antar model

No	Model	AUC	Accuracy
1.	*Random Forest Count Vectorizer*	0.91	0.92
1.	*Random Forest Count TF IDF Vectorizer*	0.88	0.91
2.	*Linear Support Vector Machine*	0.97	0.926

Diskusi dan Pembahasan

Berdasarkan hasil pada tabel 4.7, Peneliti mencoba untuk melakukan analisis lebih lanjut terkait dengan performa model linear *support vector machine*. Berdasarkan hasil kualitas akurasi dari *linear support vector machine* menunjukkan 92.6%. Hal ini menunjukkan akurasi *linear support vector machine* lebih baik dibandingkan *random forest*. Sementara, untuk presisi model *linear support vector machine* menunjukkan bahwa label kelas negatif presisi mencapai 96%, netral 71% dan positif 93%. Presisi pada semua sentimen di model ini, sedikit lebih baik dibandingkan dengan presisi pada model *random forest* untuk label kelas negatif dan positif, namun tidak untuk kelas netral. Terkait *recall* untuk kelas negatif 94.1 %, netral 80%, dan positif 93.4%. Terakhir, untuk *recall f-1 score, linear support vector machine* secara performa sedikit lebih di bawah *random forest*, namun untuk identifikasi label positif, model ini memiliki persentase yang lebih tinggi dari *random forest* dengan masing-masing di atas 92 %.

KESIMPULAN DAN SARAN

Berdasarkan hasil yang diperoleh dari serangkaian pengolahan data yang telah dilakukan dari mulai analisis deskriptif, analisis diagnostik, dan analisis prediktif, peneliti mencoba untuk memberikan saran dan rekomendasi sebagai bentuk implikasi penelitian yang dapat digunakan untuk meningkatkan layanan maupun menjadi fokus bagi organisasi dalam menyusun aturan turunan. Adapun beberapa poin yang sekiranya perlu dipertimbangkan oleh organisasi terkait serta seluruh *stakeholder* yang terlibat antara lain:

1. Peningkatan *engagement rate* terhadap masyarakat untuk memberikan sosialisasi terkait pelindungan data, akun, serta *security awareness* dengan mengimplementasikan beberapa program yakni antara lain:
   a. Penyusunan *content* yang menarik dan edukatif, serta *content* yang sifatnya menambah wawasan bagi masyarakat terkait keamanan data, informasi dan privasi di ruang siber.

b. Optimasi layanan admin sosmed selama 24 jam, dalam hal ini ada pada Biro Hukum dan Komunikasi Publik BSSN, untuk memberikan *update* maupun berita terkini pada ruang siber di Indonesia. Mekanisme ini dapat juga dilakukan melalui *automatic scheduled post*.
c. Penerapan model klasifikasi *machine learning* yang telah diuji dan dievaluasi untuk memberikan otomatisasi respon dan meminimalisir sentimen negatif.

2. Melakukan spesifikasi dokumen manajemen risiko dan perbaikan tata kelola.
3. Penyusunan Aturan Turunan terkait Undang-Undang Pelindungan Data Pribadi.
4. Peningkatan kualitas layanan pada institusi yang saling berkaitan.

DAFTAR PUSTAKA

[1] Aini, Z. (2023) Implementasi *Random Forest* dan *Gradient Boosting* Pada Klasifikasi Indeks Pembangunan Manusia (IPM). Bachelor's thesis, Fakultas Sains dan Teknologi UIN Syarif Hidayatullah Jakarta.
[2] Banjar, M. F., Irawati, I., Umar, F., & Hayati, L. N. (2022). *Analysis of Stroke Classification Using Random Forest Method*. ILKOM Jurnal Ilmiah, 14(3), 186-193.
[3] Chandani, V., Wahono, R. S., & Purwanto, P. (2015). Komparasi Algoritma Klasifikasi *Machine Learning* dan *Feature Selection* Pada Analisis Sentimen Review Film. *Journal of Intelligent Systems*, 1(1), 56-60.
[4] Hidayatullah, M., Alam, S., & Jaelani, I. (2021). *Sentiment Analysis of Police Performance On Twitter Users Using Naïve Bayes Method*. RISTEC Res. Inf. Syst. Technol, 2(2), 113-125.Feldman, R., Sanger, J. 2007. The text mining handbook: advanced approaches in analyzing unstructured data. Cambridge University Press.
[5] Laporan Survei Asosiasi Penyelenggara Jasa Internet Indonesia pada https://survei.apjii.or.id/
[6] Lee, Y., & Lee, J. (2015). *Binary Tree Optimization Using Genetic Algorithm For Multiclass Support Vector Machine. Expert Systems with Applications*, 42(8), 3843 – 3851. https://doi.org/10.1016/j.eswa.2015.01.022
[7] Leelawat, N., Jariyapongpaiboon, S., Promjun, A., Boonyarak, S., Saengtabtim, K., Laosunthara, A., ... & Tang, J. (2022). *Twitter Data Sentiment Analysis Of Tourism In Thailand During The COVID-19 Pandemic Using Machine Learning.* Heliyon, 8(10).
[8] Liu, B. (2012). "*Sentiment Analysis and Opinion Mining*." *Synthesis Lectures on Human Language Technologies, Morgan & Claypool Publishers*.
[9] Liu, Y., Yu, X., Huang, J. X., & An, A. (2011). *Combining Integrated Sampling With SVM Ensembles For Learning From Imbalanced Datasets*. Information Processing and Management, 47(4), 617–631.
[10] Putri, R. N., Setiawan, D., & Marwan, D. (2021). Implementasi Aplikasi PosyanduQ Berbasis Mobile Pada Kader dan Masyarakat Untuk Meningkatkan Pelayanan Kesehatan. *JDISTIRA-Jurnal Pengabdian Inovasi dan Teknologi Kepada Masyarakat*, *I*(1), 18-24
[11] Religia, Y., Nugroho, A., & Hadikristanto, W. (2021). Analisis Perbandingan Algoritma Optimasi pada Random Forest untuk Klasifikasi Data Bank Marketing. Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi), 5(1), 187-192.
[12] Undang-Undang Nomor 27 Tahun 2022 Mengenai Pelindungan Data Pribadi diakses pada https://peraturan.bpk.go.id/Details/229798/uu-no-27-tahun-2022
[13] Y. Pristyanto and I. Pratama, "Missing values estimation on multivariate dataset: Comparison of three type methods approach," 2019 Int. Conf. Inf. Commun. Technol. ICOIACT 2019, pp. 342–347, 2019, doi: 10.1109/ICOIACT46704.2019.8938472
[14] Yin, Y., Han, D., & Cai, Z. (2011). *Explore Data Classification Algorithm Based on SVM and PSO for Education Decision*. *Journal of Convergence Information Technology*, 6(10), 122–128.
[15] Johnson, R. B., & Christensen, L. (2019). Educational research: Quantitative, qualitative, and mixed approaches (7th ed.). SAGE Publications.
[16] Astuti, S. P. (2020). *Analisis sentimen berbasis aspek pada aplikasi tokopedia menggunakan lda dan naïve bayes* (Bachelor's thesis, Fakultas Sains dan Teknologi Universitas Islam Negeri Syarif Hidayatullah Jakarta).
[17] Al Amrani, Y., Lazaar, M., & El Kadiri, K. E. (2018). Random Forest And Support Vector Machine Based Hybrid Approach To Sentiment. Analysis. Procedia Computer Science, 127, 511-520.
[18] Rahardi, M., Aminuddin, A., Abdulloh, F. F., & Nugroho, R. A. (2022). Sentiment Analysis of Covid-19 Vaccination using Support Vector Machine in Indonesia. International Journal of Advanced Computer Science and Applications, 13(6).
[19] Laporan Lanskap Keamanan Siber 2022 oleh Badan Siber dan Sandi Negara diakses pada https://csirt.perhutani.co.id/?p=3183